

Statistica Applicata anno 2023-2024

Università degli Studi di Salerno

Dipartimento di Ingegneria dell'Informazione ed Elettrica e Matematica Applicata

Corso di Laurea in Ingegneria Informatica

Statistica Applicata 2023/2024

Analisi di un dataset in R

Gruppo n. 4

Matricola	Cognome	Nome
0612705917	Anzivino	Giuseppe Fabrizio
0612706468	De Luca Parisi	Alessandro
0612705521	De Piano	Angelo
0612704670	Pisanzio	Francesco

Indice

1. Introduzione....3
2. Recupero ed eventuale pulizia del dataset....5
3. Analisi di dati attraverso gli strumenti della statistica descrittiva....7
3.1. Indici sintetici....7
3.2. Box Plot....8
3.3. Frequenza relativa e relativa cumulata....11
3.4. Istogrammi e Grafici a Gradino....15
3.5. Scatter Plot....17
3.6. Analisi di correlazione....18
3.7. Normal Q-Q plot....20
4. Analisi delle relazioni tra variabili....22
4.1. Prima variabile indipendente: RAM....22
4.2. Seconda variabile indipendente: CPU....23
4.3. Terza variabile indipendente: Hard Disk....24
4.4. Quarta variabile indipendente: Congestione....25
4.5. Quinta variabile indipendente: Buffer....26
5. Determinazione del modello statistico....27
6. Stima dei minimi quadrati....31
6.1. Stima degli intervalli di confidenza....32
7. Analisi dei residui e diagnostica....34
7.1. Verifica degli assunti di base del modello di regressione lineare....34
8. Adattamento del modello di Regressione....37
8.1. Forward Selection....38
8.2. Backward Selection....39
8.3. Stepwise Selection....40
9. Presentazione ed analisi dei risultati....42

1. Introduzione

L'analisi dei dataset consiste nel manipolare i dati grezzi per scoprire informazioni utili e trarre conclusioni appropriate. Nel nostro caso, abbiamo a disposizione un dataset basato su vari parametri di calcolatori e tramite una ulteriore analisi di regressione, andremo a calcolare la relazione stimata tra una variabile dipendente e piu variabili da noi scelte tramite l'analisi dei dati.

Il dataset analizzato è composto da un insieme di 60 campioni sulle performance di un computer di tipo quantitativo continuo, ovvero nel campo dei numeri reali, avente come variabile dipendente y_PerfServer→perfomance del server, e come variabili indipendenti:

- x1_RAM -> memoria ram;
- x2_CPU -> CPU del computer;
- x3_HD -> Hard Disk
- x4_Cong -> Congestione
- x5_Buff -> Buffer

Per l'analisi preliminare dei dati faremo uso di alcuni strumenti di statistica descrittiva, quali Scatter Plot, Istogrammi, Grafici a gradino, BoxPlot e Normal Q-Q Plot:

Scatter Plot: un grafico a dispersione, o grafico a nuvola di punti, in cui due variabili di un set di dati sono riportate su uno spazio cartesiano. I dati sono visualizzati tramite una collezione di punti, ognuno dei quali con una posizione sull'asse orizzontale determinata da una variabile e sull'asse verticale determinata dall'altra.

Istogramma: strumento utilizzato per rappresentare in forma grafica le informazioni contenute nel dataset. In particolare, si farà uso dell'istogramma per la distribuzione di frequenza e per la distribuzione cumulata di frequenza. L'istogramma per la distribuzione di frequenza consiste in un grafico che si ottiene riportando diversi rettangoli, il cui numero corrisponde al numero delle classi in cui è suddivisa la variabile. L'altezza del rettangolo, invece, risulta proporzionale alla frequenza o alla frequenza relativa associata alla classe. Nel caso di variabili di tipo qualitativo, a differenza degli altri, non vi è uno specifico ordinamento a cui dover sottostare. Nel caso di variabili di tipo quantitativo discreto, oltre l'ordinamento, ha importanza anche l'ampiezza dei rettangoli che vanno ad indicare l'intervallo di interesse della classe. Per quanto riguarda l'istogramma per la distribuzione cumulata di frequenza, questo si presenta come un grafico a gradini che riporta per ogni classe il valore della frequenza cumulata fino a quel punto.

BoxPlot: strumento utilizzato per rappresentare una funzione empirica e per fornire la posizione e le informazioni sulle variazione dei dati. Risulta molto utile per capire se la distribuzione è simmetrica oppure asimmetrica e per confrontare la forma di più distribuzioni. Permette soprattutto di identificare in modo rapido e preciso valori anomali e outliers. Un box plot si basa su quello che è noto come riepilogo a cinque numeri in un certo set di dati:

- il valore minimo(Q0),
- il 25° percentile(Q1),
- il 50° percentile o mediana(Q2),
- il 75° percentile(Q3),
- il valore massimo(Q4).

Normal Q-Q Plot: strumento utilizzato per realizzare un grafico di probabilità normale, o più specificamente un grafico quantile-quantile (QQ), che mostra la distribuzione dei dati rispetto alla distribuzione normale prevista. Un grafico di distribuzione cumulativa viene prodotto tracciando i dati ordinati rispetto ai valori di distribuzione cumulativa. Lo stesso processo viene eseguito per una distribuzione normale standard (una distribuzione gaussiana con una media di 0 e una deviazione standard di 1). Una volta generati questi due grafici di distribuzione cumulativa, i valori dei dati corrispondenti a quantili specifici vengono accoppiati e tracciati in un grafico QQ.

2. Recupero ed eventuale pulizia del dataset

Attraverso l'ambiente di sviluppo R importiamo il dataset fornito nel file.csv e ci assicuriamo che i dati rispettino 2 regole principali:

1. I dati devono essere caricati in un data frame, con i nomi delle colonne definiti in modo che siano corretti e significativi;

2. Ogni colonna è del tipo corretto, nel nostro caso I valori sono tutti di tipo numeric;

In seguito bisogna assicurarci che essi siano consistenti, ossia bisogna passare per le caratteristiche di interesse che identificano l'appartenenza della variabile al campione (o al popolamento). Nel caso potrebbero verificarsi modifiche o eliminazioni di alcuni dati raccolti. Il primo controllo che viene fatto consiste nell'eventuale presenza di entry vuote. Nel nostro caso la tabella è pienamente popolata e quindi non è necessarie effettuare modifiche o eliminazioni.

Per assicurarci che non ci siano state discrepanze, è stato utilizzato il comando str() in modo da accertare che il data frame sia tutto accurato. Tale comando risulta utile per ottenere una struttura sintetica dell'oggetto che fornisce informazioni dettagliate e compatte su diversi aspetti del sistema, permettendo di capire la composizione dei dati senza visualizzarli completamente. Risulta possibile notare che le colonne hanno nomi significativi e differenti tra di loro, e i dati contenuti sono univocamente valori numerici.

```
> str(df)
'data.frame':   60 obs. of  6 variables:
 $ y_PerfServer: num  86 81.4 86 86.1 91.5 ...
 $ x1_RAM      : num  -1.2785 1.1225 -0.6466 -0.0776 0.4478 ...
 $ x2_CPU      : num  -1.181 0.397 -1.143 1.485 1.009 ...
 $ x3_HD       : num  -1.715 -1.547 1.39 0.691 0.786 ...
 $ x4_Cong     : num  -1.4407 0.0617 -1.1856 -0.5047 -1.573 ...
 $ x5_Buff     : num  0.77 -0.88 -0.751 -1.664 0.205 ...
```

Infine è stata utilizzata la funzione View() per visualizzare il data frame nella sua forma tabellare in modo da esaminare i dati in un formato leggibile e simile ad un foglio di calcolo.

	y_PerfServer	x1_RAM	x2_CPU	x3_HD	x4_Cong	x5_Buff
1	86.04281	-1.27848778	-1.18131258	-1.71507055	-1.44066318	0.76999071
2	81.35362	1.12251475	0.39669517	-1.54653287	0.06172286	-0.88011317
3	86.01225	-0.64656664	-1.14268483	1.38998864	-1.18558056	-0.75075219
4	86.12061	-0.07761732	1.48528763	0.69148869	-0.50471226	-1.66377825
5	91.47771	0.44775158	1.00897084	0.78634584	-1.57301104	0.20479877
6	78.22156	0.73476459	0.74992232	1.15536587	0.70135312	-0.10312640
7	74.38727	-1.24476022	-1.48836905	0.17942810	-0.44986503	1.04905864
8	102.34492	1.51576263	0.86227388	0.61858221	-1.31635011	-0.06438398
9	90.72866	-0.53064145	1.02227775	0.29648077	-1.00463360	-1.57203196
10	69.95545	0.01228128	1.44316941	1.54673955	1.42717115	-1.29791341
11	91.56731	1.53263502	1.51514938	-1.03453360	1.35464708	0.68675126
12	73.13053	0.97912922	-0.98791197	1.33163882	0.85110376	0.50475667
13	88.04848	0.87109887	-0.74448781	-0.15475470	-1.26695063	-0.91385993
14	86.35917	0.61659062	1.63333130	-0.12684790	0.77399466	-0.22625602

Showing 1 to 14 of 60 entries, 6 total columns

Arrivati questo punto è possibile passare alla fase successiva: l’analisi descrittiva.

3. Analisi di dati attraverso gli strumenti della statistica descrittiva

In questa fase vogliamo ottenere una prima descrizione visuale dei dati raccolti, controllare la presenza di outliers e/o anomalie, e di conseguenza rimuoverle e valutare le relazioni tra le variabili.

3.1. Indici sintetici

Risulta utile fare riferimento anche a particolari indici sintetici che, pur contenendo un livello di informazione inferiore rispetto a quello contenuto nella distribuzione di frequenza, danno comunque indicazioni utili su specifici aspetti del problema. In particolare:

- Indici di tendenza centrale (o di posizione) che hanno lo scopo di indicare intorno a quali valori tendono ad addensarsi i valori della caratteristica di interesse. Tali indici sono Media, Mediana e Moda.

- Indici di dispersione che hanno lo scopo di dare una misura della variabilità nelle osservazioni e, quindi, di dare indicazioni sulla tendenza di tali valori a differire tra loro. Tali indici sono Escursione Campionaria (o Range), Varianza e Deviazione Standard.

Mediante la funzione *summary()* andiamo a fare un resoconto del dataset mettendo in evidenza minimo, primo quartile, mediana, media, terzo quartile e massimo di ogni colonna. In questo modo è possibile evidenziare anche alcuni degli indici di posizione, come la media e la mediana:

Indici	Perf-Server	RAM	CPU	HD	CONG	BUFF
Minimo	61.16	- 1.69327	- 1.67510	- 1.7151	- 1.66078	- 1.7261
1° Quartile	74.59	- 0.79372	- 0.72223	- 0.8883	- 0.68414	- 0.9257
Mediana	83.18	- 0.11451	- 0.05674	- 0.1408	0.05916	- 0.2061
Media	81.66	- 0.03851	0.02104	- 0.0624	0.06266	- 0.1668
3° Quartile	88.08	0.70273	0.86058	0.7141	0.89699	0.6641
Massimo	102.34	1.64624	1.63333	1.6919	1.65471	1.7261

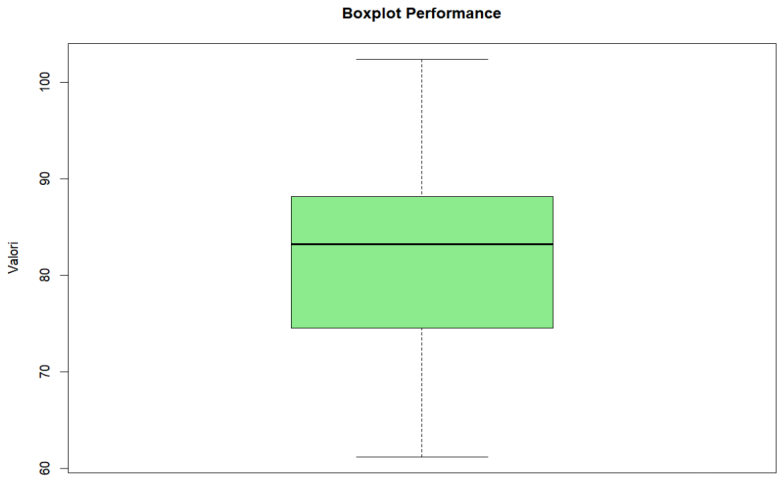
Infine per quanto riguarda gli indici di dispersione, di seguito sono indicati i valori in maniera tabellare:

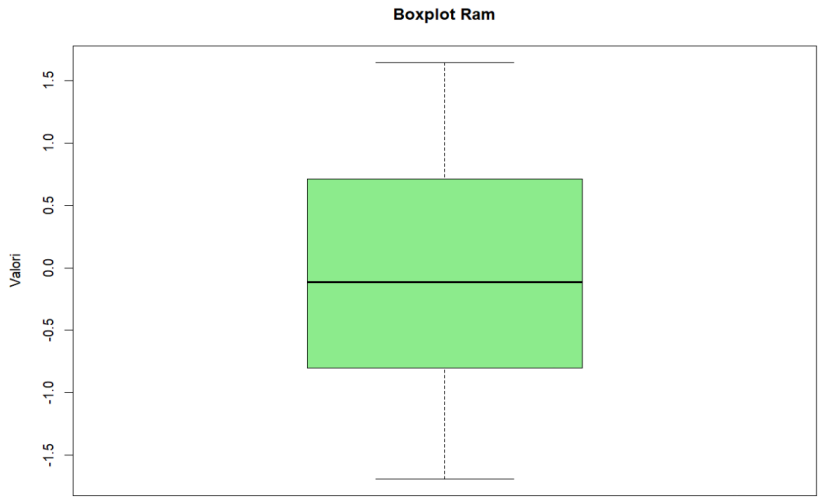
Indici	Perf-Serve	RAM	CPU	HD	CONG	BUFF
Range	41.19	3.34	3.31	3.41	3.32	3.45
Varianza	78.90	0.989	0.997	0.963	0.951	0.914
Deviazione Standard	8.88	0.995	0.998	0.981	0.975	0.956

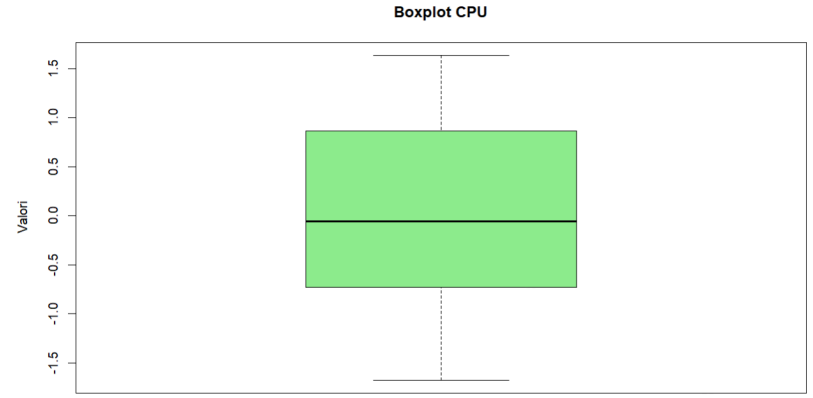
Da questi dati risulta possibile intuire che per le variabili indipendenti (Ram, CPU, HD, Congestione, Buffer) si hanno valori che si aggirano intorno allo zero, suggerendo che i dati si aggirano intorno a numeri molto piccoli. La dispersione, come indicato dalle varianze, risulta abbastanza consistente (con valori molto vicino all'1). Ciò indica che, sebbene le medie siano prossime allo zero, i valori possono variare significativamente attorno a tali valori centrali. Per quanto riguarda la variabile dipendente (Performance), questa possiede una media molto più alta (81.66) e un'altrettanta alta varianza (78.90) indicando così sia un valore centrale alto che una grande dispersione dei dati.

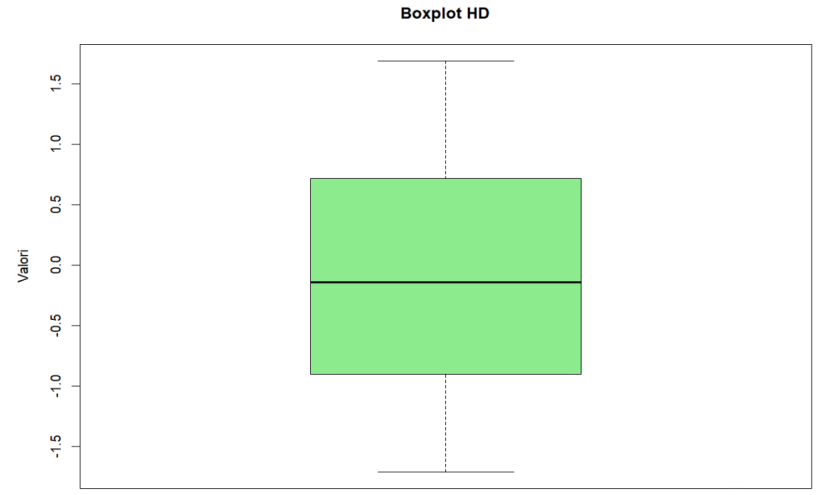
3.2. Box Plot

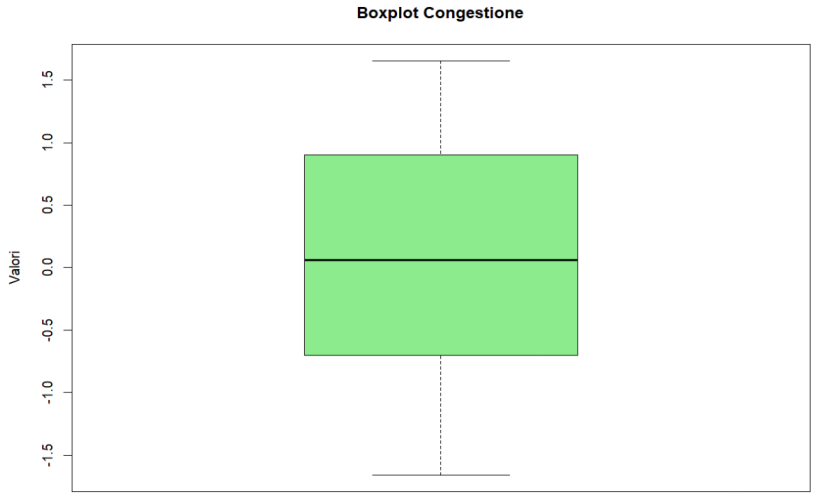
I 5 parametri ottenuti dal summary() possono essere usati per definire i Box Plot, i quali però vengono definiti in maniera più semplice attraverso l'ausilio del comando boxplot() su R Studio.

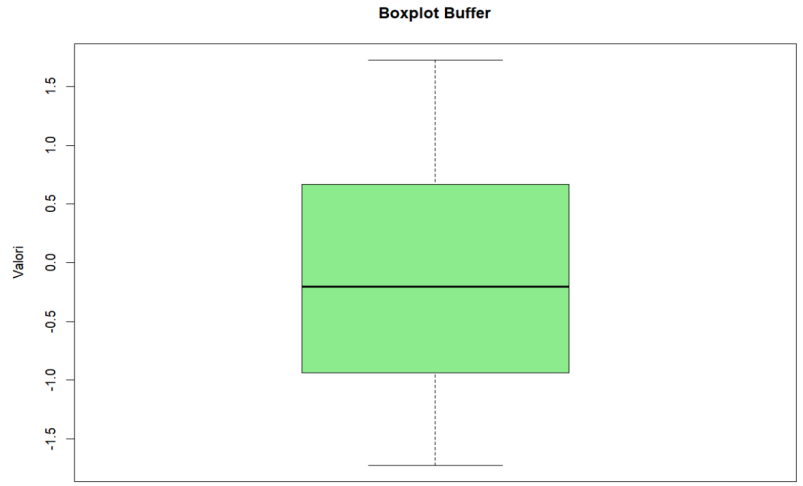



Boxplot Ram
Valori
1.5
1.0
0.5
0.0
-0.5
-1.0
-1.5


Boxplot CPU
Valori
1.5
1.0
0.5
0.0
-0.5
-1.0
-1.5


Boxplot HD
Valori
1.5
1.0
0.5
0.0
-0.5
-1.0
-1.5





I Box Plot presentano tre elementi principali, i quali sono:

- Box, o scatola, che presenta un:
  - limite superiore, corrispondente al 25° percentile,
  - limite inferiore, corrispondente al 75° percentile,
  - linea mediana, corrispondente al 50° percentile.
- Baffi, si estendono fino ai valori massimi e minimi all'interno di un intervallo definito, solitamente calcolato come 1.5 l'IQR (l'Interquartile Range).
- Outliers, dati al di fuori dei limiti definiti dai baffi.

La linea mediana viene utilizzata pure per definire se la distribuzione dei dati è simmetrica o meno. Se si trova centrale allora si tratta di una distribuzione risulta simmetrica, altrimenti il contrario. Da ciò risulta evidente che la distribuzione della performance è asimmetrica a sinistra (a causa del fatto che si avvicina a Q1). Inoltre da come è possibile evidenziare non sono presenti outliers.

3.3. Frequenza relativa e relativa cumulata

Uno strumento molto utilizzato per la sintesi dell'informazione sono la distribuzione di frequenza relativa e la distribuzione di frequenza relativa cumulata. Per calcolare tali informazioni, trattandosi di variabili di tipo quantitativo continuo, bisogna andare a dividere la popolazione in classi il cui numero può essere definito attraverso l'uso della norma UNI 4724-66 con la quale deduciamo che tale valore deve essere minore o uguale a 8. Per determinarlo in modo semplice e sicuro si utilizza una funzione che mette in gioco la numerosità della popolazione (60):

$$K = 1 + 3.3 \log_{10}(N) = 6.86 \cong 7$$

In conclusione bisogna andare a dividere gli intervalli, ricavati dai valori di minimo e massimo calcolati precedentemente, in 7 classi di uguale ampiezza. Per quanto riguarda le variabili indipendenti procediamo con i seguenti calcoli:

RAM

Classi	Centro di Classe	Frequenza	Frequenza Relativa	Frequenza Cumulata	Frequenza Relativa Cumulata
$-1.69 \leq i < -1.22$	-1.45	12	0.20	12	0.20
$-1.22 \leq i < -0.74$	-0.98	4	0.07	16	0.27
$-0.74 \leq i < -0.26$	-0.50	10	0.17	26	0.44
$-0.26 \leq i < 0.22$	-0.02	8	0.13	34	0.57
$0.22 \leq i < 0.69$	0.45	11	0.18	45	0.75
$0.69 \leq i < 1.17$	0.93	7	0.12	52	0.87
$1.17 \leq i < 1.65$	1.41	8	0.13	60	1

CPU

Classi	Centro di Classe	Frequenza	Frequenza Relativa	Frequenza Cumulata	Frequenza Relativa Cumulata
$-1.68 \leq i < -1.20$	-1.44	8	0.13	8	0.13
$-1.20 \leq i < -0.73$	-0,97	7	0.116	15	0.253
$-0.73 \leq i < -0.26$	-0.49	11	0.183	26	0.43
$-0.26 \leq i < 0.22$	-0.02	8	0.13	34	0.56
$0.22 \leq i < 0.69$	0.45	8	0.13	42	0.70
$0.69 \leq i < 1.16$	0.92	9	0.15	51	0.85
$1.16 \leq i \leq 1.64$	1.40	9	0.15	60	1.00

HD

Classi	Centro di Classe	Frequenza	Frequenza Relativa	Frequenza Cumulata	Frequenza Relativa Cumulata
$-1.72 \leq i < -1.23$	-1.47	11	0.18	11	0.18
$-1.23 \leq i < -0.74$	-0,99	7	0.12	18	0.30
$-0.74 \leq i < -0.26$	-0.50	8	0.13	26	0.43
$-0.26 \leq i < 0.23$	-0.01	12	0.20	38	0.63

$0.23 \leq i < 0.72$	0.48	7	0.12	45	0.75
$0.72 \leq i < 1.21$	0.96	6	0.10	51	0.85
$1.21 \leq i \leq 1.70$	1.45	9	0.15	60	1

CONGESTIONE

Classi	Centro di Classe	Frequenza	Frequenza Relativa	Frequenza Cumulata	Frequenza Relativa Cumulata
$-1.66 \leq i < -1.19$	-1.42	7	0.12	7	0.12
$-1.19 \leq i < -0.71$	-0,95	8	0.13	15	0.25
$-0.71 \leq i < -0.24$	-0.48	12	0.20	27	0.45
$-0.24 \leq i < 0.23$	-0.003	6	0.10	33	0.55
$0.23 \leq i < 0.71$	0.47	6	0.10	39	0.65
$0.71 \leq i < 1.18$	0.94	11	0.18	50	0.83
$1.18 \leq i \leq 1.66$	1.42	10	0.17	60	1

BUFFER

Classi	Centro di Classe	Frequenza	Frequenza Relativa	Frequenza Cumulata	Frequenza Relativa Cumulata
$-1.73 \leq i < -1.23$	-1.48	10	0.17	10	0.17
$-1.23 \leq i < -0.74$	-0,99	10	0.17	20	0.34
$-0.74 \leq i < -0.25$	-0.49	9	0.15	29	0.49
$-0.25 \leq i < 0.25$	-0.018	11	0.18	40	0.67
$0.25 \leq i < 0.74$	0.49	7	0.12	47	0.79
$0.74 \leq i < 1.23$	0.99	8	0.13	55	0.92
$1.23 \leq i \leq 1.74$	1.48	5	0.08	60	1

Da tali tabelle, è possibile intuire che vi è una buona distribuzione di frequenza relativa e di frequenza relativa cumulata con valori che si bilanciano tra valori negativi e positivi. Infatti la distribuzione risulta uniforme ed equilibrata alle classi definite in quanto non vi è un'evidente concentrazione di osservazioni in una singola di esse. Passando ora alla variabile dipendente procediamo con i seguenti calcoli:

PERFORMANCE

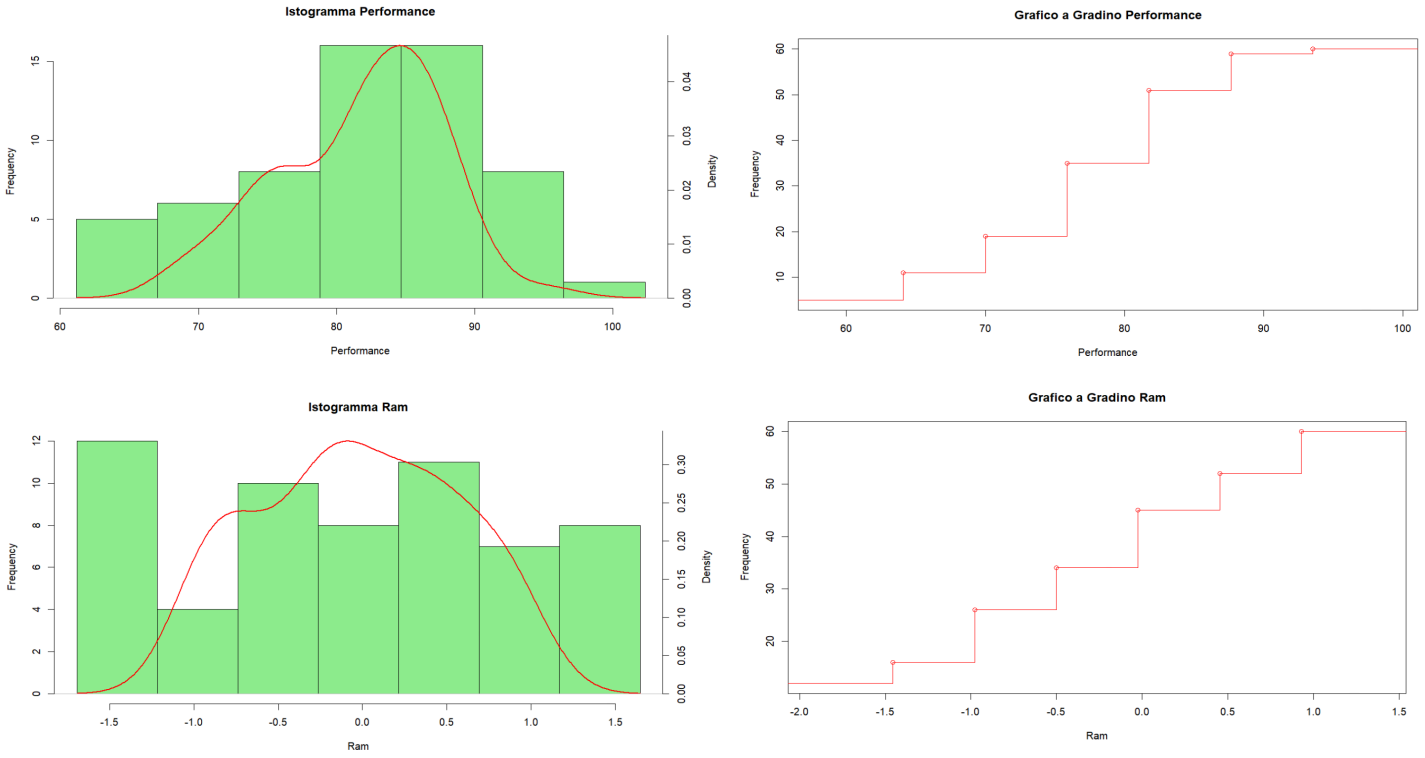
Classi	Centro di Classe	Frequenza	Frequenza Relativa	Frequenza Cumulata	Frequenza Relativa Cumulata
$61.2 \leq i < 67$	64.1	5	0.08	5	0.08
$67 \leq i < 72.9$	70	6	0.10	11	0.18

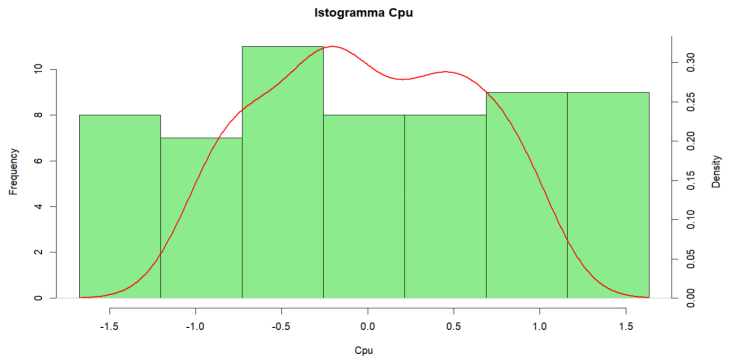
$72.9 \leq i < 78.8$	75.9	8	0,13	19	0.31
$78.8 \leq i < 84.7$	81.8	16	0.27	35	0.58
$84.7 \leq i < 90.6$	87.6	16	0.27	51	0.85
$90.6 \leq i < 96.5$	93.52	8	0.13	59	0.98
$96.5 \leq i \leq 102.5$	99.4	1	0.02	60	1

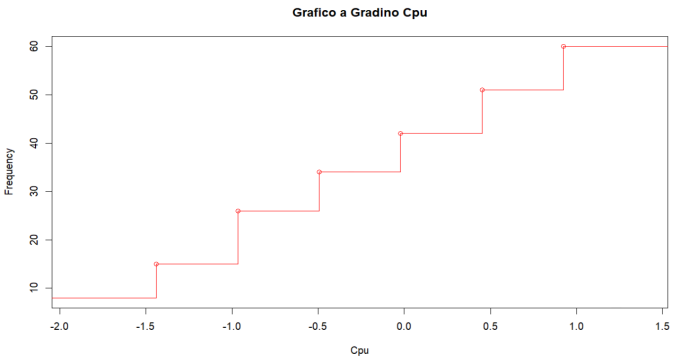
Da tale tabella è possibile intuire che vi è un'elevata concentrazione di dati negli intervalli centrali della distribuzione, come mostrato dai centri di classe e gli elevati valori di frequenza e frequenza cumulata. Tutto ciò suggerisce una distribuzione dei dati con una chiara tendenza verso la zona centrale e con una concentrazione minore sugli estremi.

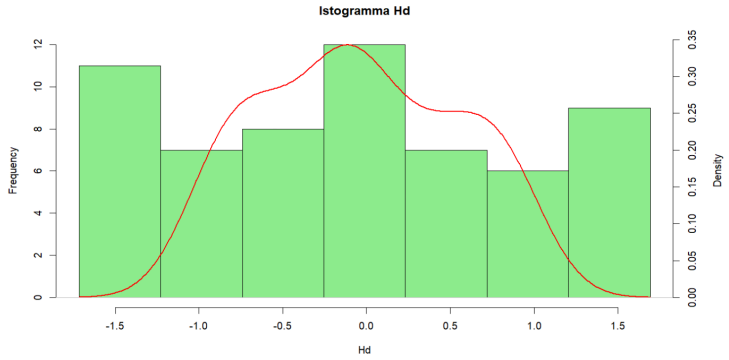
3.4. Istogrammi e Grafici a Gradino

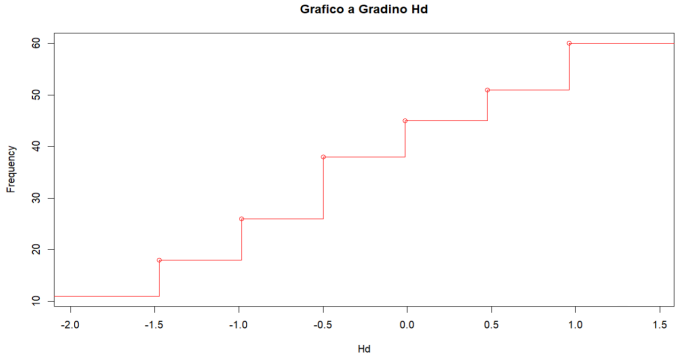
Attraverso i dati forniti dal calcolo delle frequenze relative è possibile fornire una rappresentazione grafica della distribuzione di frequenza relativa attraverso l'uso degli istogrammi e della distribuzione di frequenza cumulata attraverso l'uso dei grafici a gradino. A questi è stata aggiunta la rappresentazione della densità di frequenza:

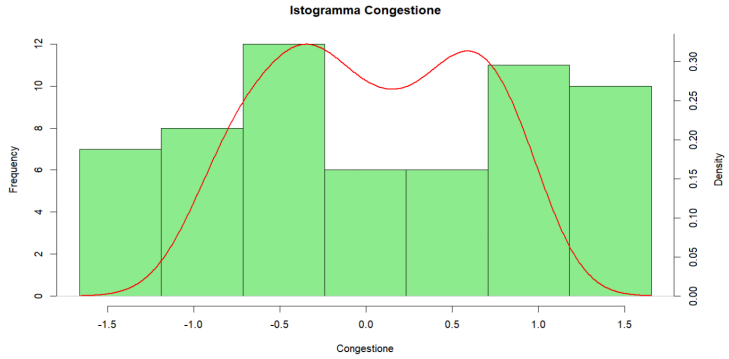


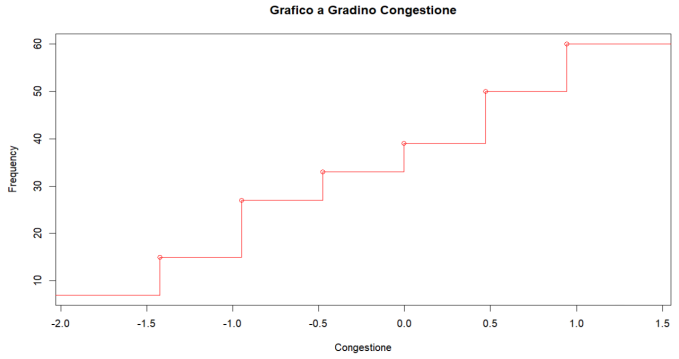

Istogramma Cpu
Frequency
Density
Cpu

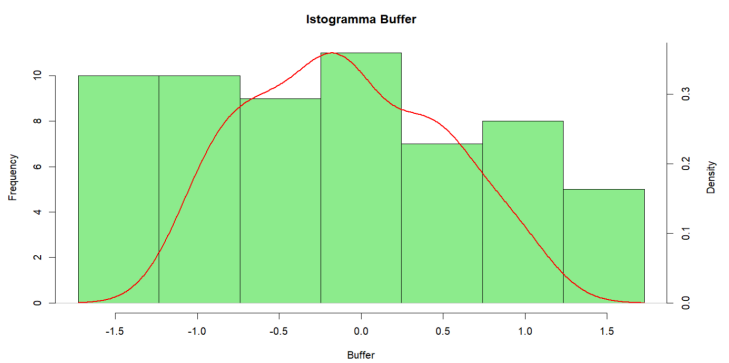

Grafico a Gradino Cpu
Frequency
Cpu

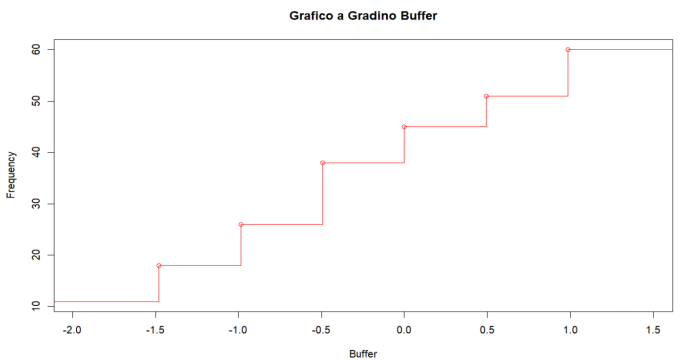

Istogramma Hd
Frequency
Density
Hd


Grafico a Gradino Hd
Frequency
Hd


Istogramma Congestione
Frequency
Density
Congestione


Grafico a Gradino Congestione
Frequency
Congestione

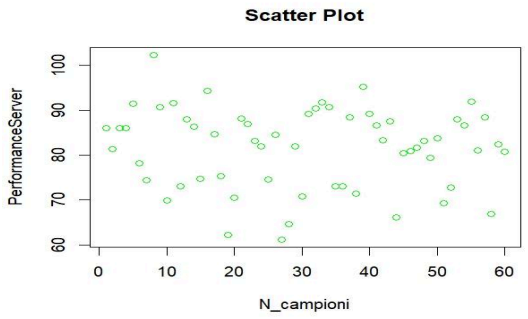

Istogramma Buffer
Frequency
Density
Buffer

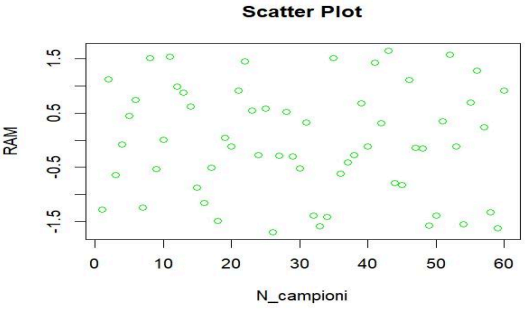

Grafico a Gradino Buffer
Frequency
Buffer

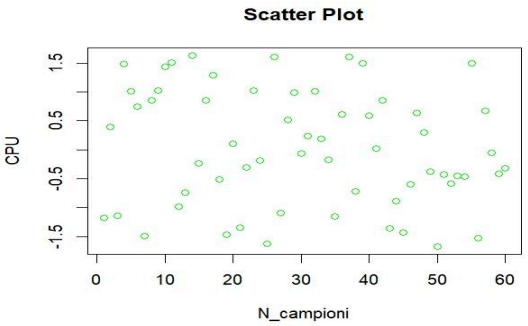
Dall'interpretazione visiva degli istogrammi, ottenuti sulle variabili dipendenti e indipendenti del dataset, non emerge la presenza di una simmetria evidente e marcata. Tuttavia, risulta possibile osservare alcuni tratti simmetrici che suggeriscono una distribuzione che tende a quella Normale. Per quanto riguarda l'interpretazione visiva dei grafici a gradino, basati anch'essi dalle variabili dipendenti e indipendenti del dataset, non viene mostrato alcun aumento rapido della frequenza. L'unico aumento più significativo degli altri risulta solo nella variabile "performance" dove, come precedentemente menzionato, vi è una maggiore concentrazione centrale.

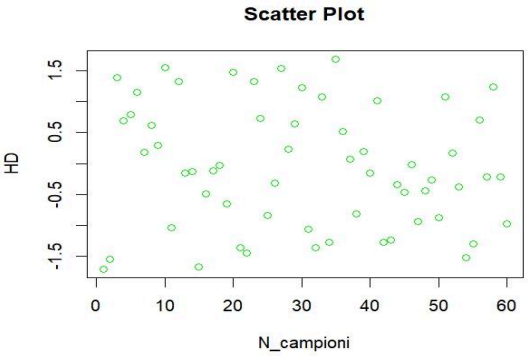
3.5. Scatter Plot

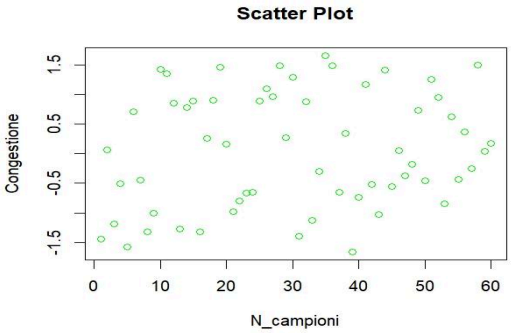
Per una migliore analisi attraverso gli strumenti della statistica descrittiva, è possibile andare a descrivere visivamente la distribuzione delle variabili dipendenti e indipendenti attraverso gli scatter plot:

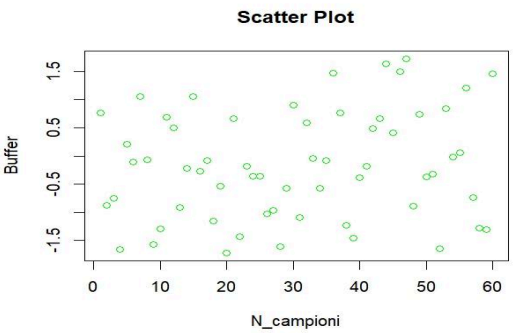






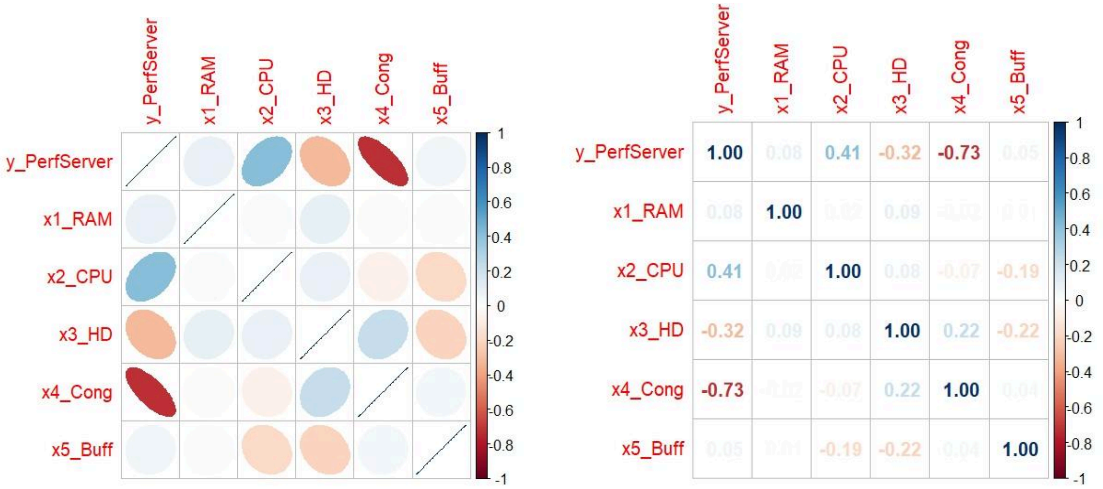


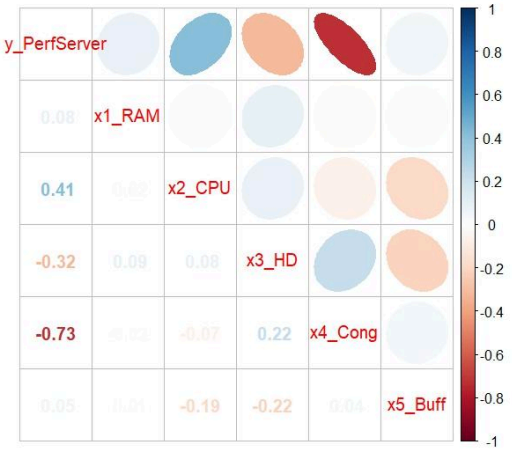




3.6. Analisi di correlazione

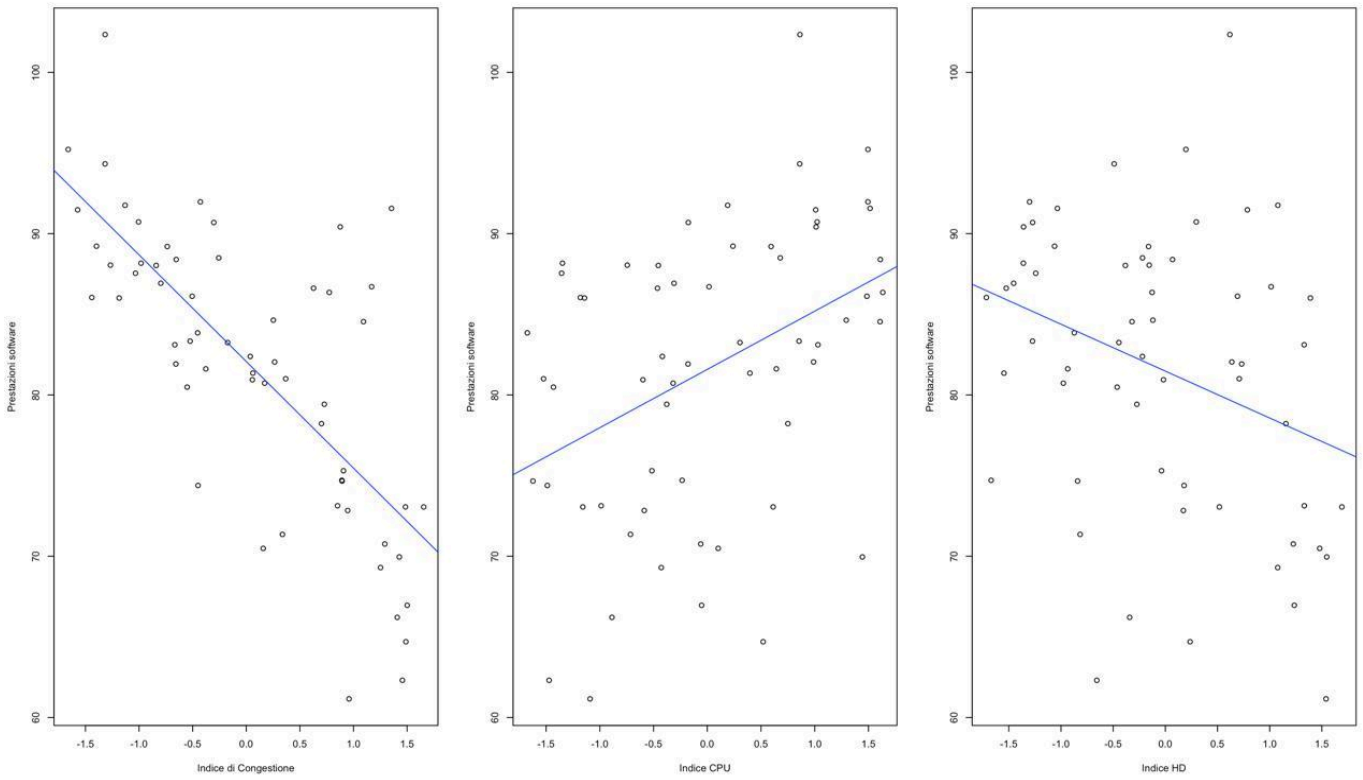
L'analisi di correlazione, in particolare il diagramma di correlazione, è un utile metodo preliminare per analizzare l'eventuale presenza di un legame tra le variabili indipendenti e la variabile dipendente. Una misura quantitativa del "grado di associazione'' tra due variabili è fornita dal cosiddetto coefficiente di correlazione R, ossia un numero compreso tra -1 e 1. Quanto più esso è prossimo ad 1, in valore assoluto, tanto più il grado di associazione tra le variabili è elevato, viceversa quanto più esso è prossimo a 0 tanto più il grado di associazione è basso. Valori positivi di R indicano una correlazione positiva, valori negativi indicano una correlazione negativa, valore R=1 (R=-1) indica perfetta correlazione positiva (negativa), mentre il valore R=0 indica completa assenza di correlazione. Per svolgere tale analisi, all'interno di R studio abbiamo utilizzato le funzioni **cor()** e **corrplot()** che ci hanno permesso di ottenere rispettivamente un correlation plot e una matrice di correlazione, per poter osservare sia graficamente che tramite i valori del coefficiente R, in che modo sono correlate le variabili.

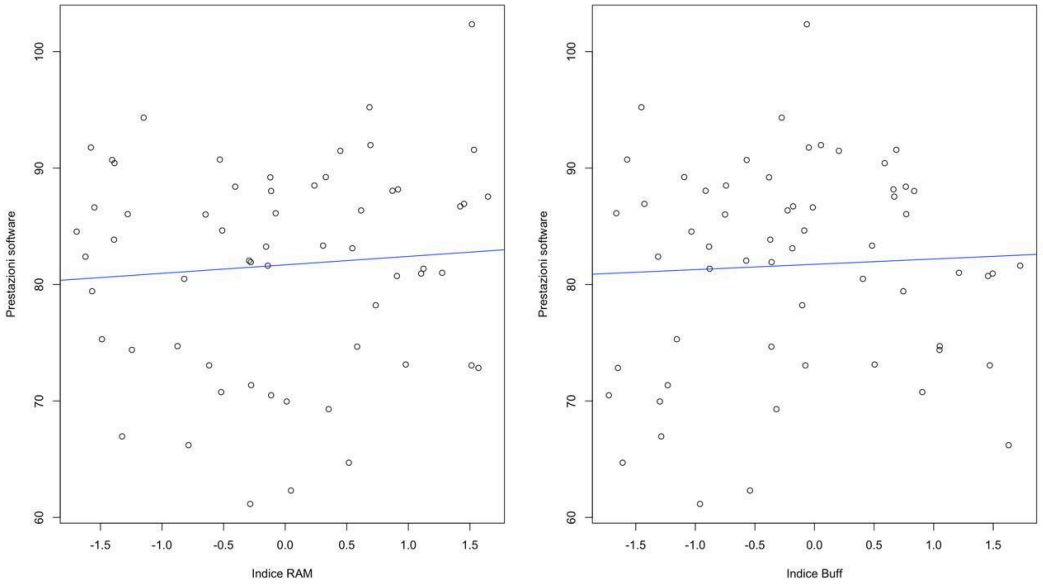




Guardando il grafico a primo impatto, risulta evidente notare una correlazione lineare inversa tra la congestione e le prestazioni. Inoltre è possibile notare anche nel dettaglio la correlazione lineare inversa di -0.73 tra la congestione e le prestazioni e la correlazione lineare di 0.41 tra la CPU e le prestazioni. In seguito attraverso l'utilizzo

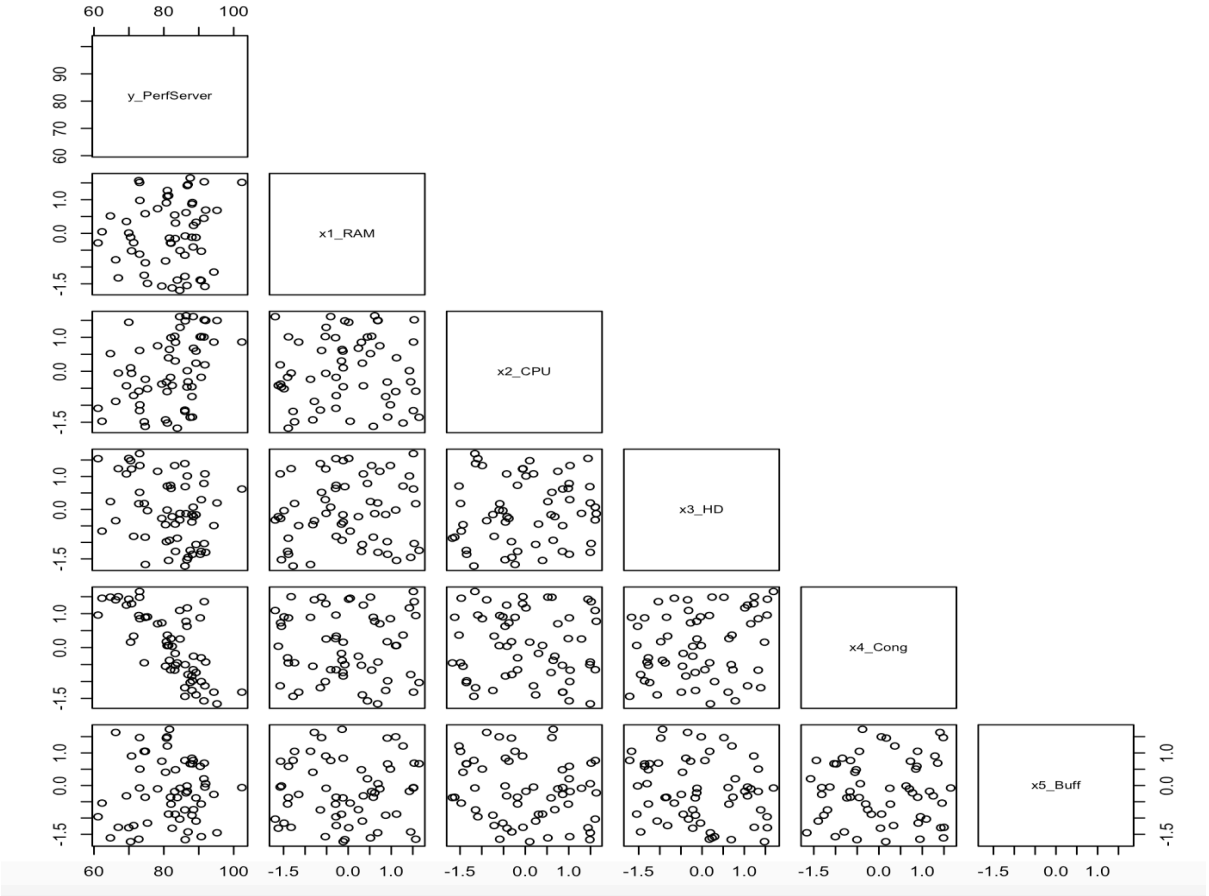
della funzione **ggplot()** è stato possibile creare anche degli scatter plot di correlazione con una stima della possibile retta di regressione (in blu) tra ogni variabile indipendente e la variabile dipendente.





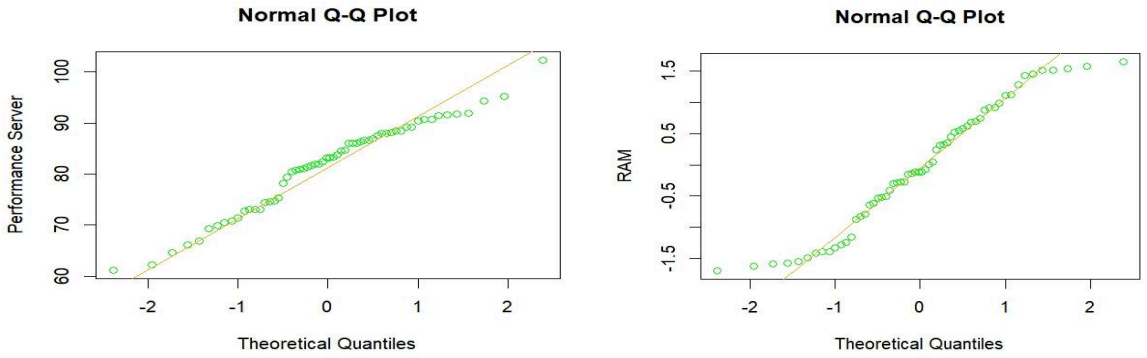
Da tali grafici risulta possibile cogliere meglio il fatto che vi è una forte anti correlazione tra la variabile dipendente e quelle indipendenti di Ram e Buffer. Per una descrizione

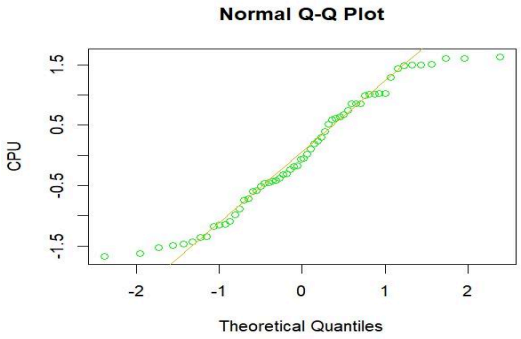
visiva più dettagliata dell'analisi di correlazione è possibile usare anche gli scatter plot fornendo così il seguente grafico:

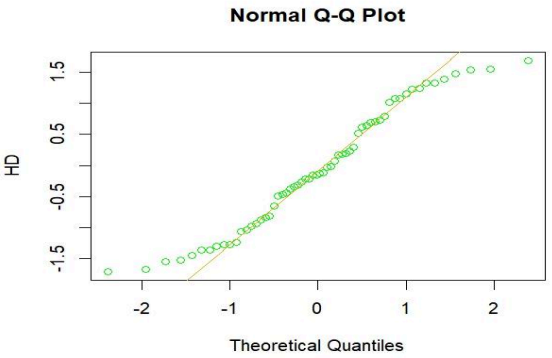


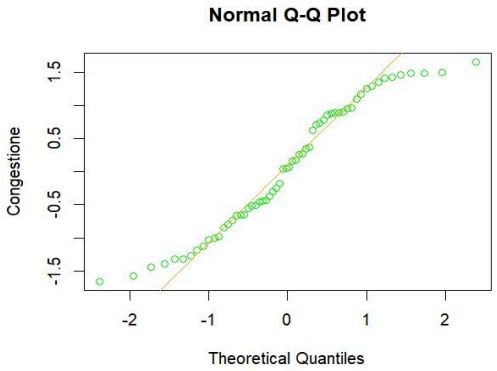
3.7. Normal Q-Q plot

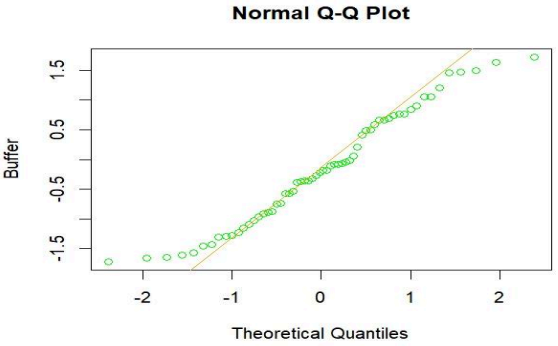
Un altro strumento usato nella statistica descrittiva consiste nell'utilizzo della Normal Q-Q Plot, ossia la rappresentazione grafica dei quantili di una distribuzione. Risulta efficace per verificare la normalità dei dati, identificare la presenza di valori estremi e confrontare la distribuzione dei dati osservati con una distribuzione teorica, in questo caso la Normale.











Dai grafici generati tramite le funzioni "**qqnorm"** e "**qqline"** risulta possibile osservare che i quantili vanno ad addensarsi lungo la diagonale di riferimento. Questo suggerisce che le variabili osservate seguono approssimativamente una distribuzione Normale accompagnata da code che deviano: in basso a sinistra e in alto a destra. Tali deviazioni indicano eventuali outliers rispetto alla distribuzione teorica prevista.

4. Analisi delle relazioni tra variabili

In seguito alla parte di statistica descrittiva, è possibile passare ad una fase di analisi delle relazioni tra variabili. Per fare ciò andiamo ad utilizzare la regressione polinomiale, consistente nella ricerca di un modello che meglio approssima le relazioni tra variabile dipendente e indipendente, prestando attenzione ad un possibile overtraining. Per fornire osservazioni più dettagliate e per prendere una decisione riguardo l'esclusione della variabile andiamo ad utilizzare due indici di bontà di adattamento:

- il p-value è utilizzato per determinare la significatività statistica dei coefficienti di regressione delle variabili indipendenti (regressori), prendendo come riferimento una soglia di significatività, compresa solitamente tra 0.05 e 0.01, se il valore del p-value è più basso di questa soglia, possiamo considerare significativo l'effetto che ha la variabile indipendente su quella indipendente, e viceversa per i valori superiori alla soglia.
- Il Multiple R-Squared o anche R^2 se risulta un valore basso di R^2 significa che il modello complessivo non spiega bene la varianza della variabile dipendente. Un valore alto indica un buon adattamento del modello complessivo ai dati. Il valore del R^2 è compreso tra $0 \leq R^2 \leq 1$

4.1. Prima variabile indipendente: RAM

Partendo dalla valutazione della variabile indipendente Ram e considerando le osservazioni fatte in precedenza, in particolare quelle riguardanti l'analisi di correlazione, è possibile affermare di già che questa non gode di un'ottima correlazione con la variabile dipendente. Per tale motivo sarebbe già possibile trascurare tale parametro e passare a quello successivo, ma nonostante ciò andiamo lo stesso ad analizzarla attraverso l'uso dei due indici di bontà di adattamento in modo da avere osservazioni più dettagliate e per andare a rafforzare l'idea di esclusione

```
Call:
lm(formula = PerformanceServer ~ RAM, data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-20.325  -6.659   1.550   6.151  19.554

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  81.6883     1.1536  70.810   <2e-16 ***
RAM           0.7275     1.1688   0.622    0.536
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.929 on 58 degrees of freedom
Multiple R-squared:  0.006637,  Adjusted R-squared:  -0.01049
F-statistic: 0.3875 on 1 and 58 DF,  p-value: 0.5361
```

Esaminando, con l'utilizzo del comando **lm()**, la relazione tra la variabile dipendente "Performance Server" con la variabile indipendente "RAM" notiamo un p-value molto grande rispetto alla soglia di significatività e un R^2 molto piccolo.

```
Call:
lm(formula = PerformanceServer ~ RAM + I(RAM^2) + I(RAM^3), data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-17.792  -6.938   1.873   6.849  17.233

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   79.588      1.647  48.316   <2e-16 ***
RAM            2.932      3.098   0.946   0.3480
I(RAM^2)       2.097      1.232   1.703   0.0941 .
I(RAM^3)      -1.074      1.548  -0.694   0.4908
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.808 on 56 degrees of freedom
Multiple R-squared:  0.06679,   Adjusted R-squared:  0.0168
F-statistic: 1.336 on 3 and 56 DF,  p-value: 0.2719
```

Provando a fare overtraining, notiamo come il suo comportamento permane, il che ci permette di escluderlo indiscutibilmente dal nostro modello.

4.2. Seconda variabile indipendente: CPU

Passando alla variabile successiva è possibile notare sin da subito una buona correlazione con la variabile dipendente che ci consente di considerarla all'interno del nostro modello. Per avere informazioni più dettagliate si passa a svolgere un analisi basata sugli indici di bontà di adattamento:

```
Call:
lm(formula = PerformanceServer ~ CPU, data = data)

Residuals:
     Min       1Q   Median       3Q      Max
-18.7651  -4.5366   0.4314   6.3003  17.6449

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   81.584      1.057  77.172  < 2e-16 ***
CPU            3.613      1.068   3.384  0.00129 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.187 on 58 degrees of freedom
Multiple R-squared:  0.1649,    Adjusted R-squared:  0.1505
F-statistic: 11.45 on 1 and 58 DF,  p-value: 0.001285
```

Nel caso in esame, possiamo notare un valore significativo del R^2 e uno molto piccolo per quanto riguarda il p-value. Risulta possibile considerarla già un parametro importante per la determinazione del modello lineare. Nonostante ciò, viene svolta

un'ulteriore analisi in modo da valutare una relazione di tipo diverso rispetto a quello lineare:

```
Call:
lm(formula = PerformanceServer ~ CPU + I(CPU^2) + I(CPU^3), data = data)

Residuals:
     Min       1Q   Median       3Q      Max
-19.0583  -4.1833   0.9016   5.4349  16.7733

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  80.6781     1.5746  51.238   <2e-16 ***
CPU           5.7504     2.7467   2.094   0.0408 *
I(CPU^2)      0.9554     1.1860   0.806   0.4239
I(CPU^3)     -1.2093     1.4040  -0.861   0.3927
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.232 on 56 degrees of freedom
Multiple R-squared:  0.1849,    Adjusted R-squared:  0.1412
F-statistic: 4.234 on 3 and 56 DF,  p-value: 0.009106
```

Dopo di ciò è possibile concludere con certezza e sicurezza che la lineare sia la più ragionevole e che questo regressore può essere considerato nel nostro modello.

4.3. Terza variabile indipendente: Hard Disk

Per quanto riguarda tale parametro, avendo una debole anticorrelazione di tipo lineare con la variabile dipendente e valutando anche i valori del p-value e R^2, risulta possibile considerarla nel nostro modello.

```
Call:
lm(formula = PerformanceServer ~ HD, data = data)

Residuals:
     Min       1Q   Median       3Q      Max
-21.0803  -6.3548   0.5904   5.6662  22.6661

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   81.479      1.097  74.242   <2e-16 ***
HD            -2.910      1.126  -2.585   0.0123 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.484 on 58 degrees of freedom
Multiple R-squared:  0.1033,    Adjusted R-squared:  0.08786
F-statistic: 6.683 on 1 and 58 DF,  p-value: 0.01227
```

Sono state svolte ulteriori analisi attraverso l'aggiunta di parametri che forniscono un contributo diverso da quello lineare, ma nonostante ciò non è emerso un significativo beneficio portando così la relazione lineare ad essere la migliore da impiegare.

4.4. Quarta variabile indipendente: Congestione

Passando alla quarta variabile indipendente “Congestione” è possibile notare che, da come risulta dall’analisi di correlazione, gode di una fortissima anticorrelazione con la variabile dipendente. Per tale motivo va considerata all’interno del nostro modello.Per confermare tale ipotesi, come per le altre variabili, siamo andati a svolgere un'ulteriore analisi:

```
Call:
lm(formula = PerformanceServer ~ Congestione, data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-14.583  -3.070  -0.404   2.161  18.447

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  82.0744     0.7973 102.939  < 2e-16 ***
Congestione  -6.6101     0.8227  -8.035 5.35e-11 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 6.163 on 58 degrees of freedom
Multiple R-squared:  0.5268,    Adjusted R-squared:  0.5186
F-statistic: 64.56 on 1 and 58 DF,  p-value: 5.349e-11
```

Avendo un valore del p-value molto basso e un R^2 molto significativo, bisogna andare a considerarla nel nostro modello. Attraverso una seconda analisi si è arrivati alla conclusione che ulteriori parametri non sono necessari:

```
Call:
lm(formula = PerformanceServer ~ Congestione + I(Congestione^2),
    data = data)

Residuals:
     Min       1Q   Median       3Q      Max
-14.6055  -3.1692  -0.4789   2.2075  18.5974

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      82.2585     1.2343  66.645  < 2e-16 ***
Congestione      -6.5895     0.8362  -7.880 1.09e-10 ***
I(Congestione^2) -0.1973     1.0040  -0.197    0.845
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 6.215 on 57 degrees of freedom
Multiple R-squared:  0.5271,    Adjusted R-squared:  0.5105
F-statistic: 31.77 on 2 and 57 DF,  p-value: 5.384e-10
```

4.5. Quinta variabile indipendente: Buffer

In conclusione l'ultima variabile indipendente "Buffer" presenta l'indice di correlazione con la variabile dipendente più basso tra tutte. Per tale motivo si potrebbe già considerare di escluderlo dal modello lineare che bisogna determinare. Nonostante ciò viene realizzata un ulteriore analisi su osservazioni più dettagliate in modo da rendere certa la sua esclusione:

```
Call:
lm(formula = PerformanceServer ~ Buffer, data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-20.141  -7.589   1.420   6.176  20.638

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  81.7365     1.1729  69.685   <2e-16 ***
Buffer        0.4569     1.2185   0.375    0.709
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.948 on 58 degrees of freedom
Multiple R-squared:  0.002418,  Adjusted R-squared:  -0.01478
F-statistic: 0.1406 on 1 and 58 DF,  p-value: 0.7091
```

Da tale ulteriore analisi risulta anche che il p-value e l' R^2 sono altrettanto pessimi. In conclusione, essendo il suo contributo minimo, escludiamo con certezza la variabile "Buffer" dal nostro modello.

5. Determinazione del modello statistico

L'obiettivo di tale progetto consiste nell'andare a definire un modello statistico basato sulle 5 variabili indipendenti del dataset che ci aiutano a definire la distribuzione della variabile dipendente. L'approccio utilizzato per fare ciò consiste nella tecnica di stepwise forward che prevede l'aggiunta di variabili indipendenti al modello lineare svolgendo un passo alla volta (stepwise) e partendo dal modello lineare più semplice per poi complicarlo con l'aggiunta delle altre variabili (forward). Il nostro approccio si basa sul:

- coefficiente di determinazione R^2,
- Residual Sum of Square RSS $\sum_{i=1}^{n} (y_i - \hat{y}_i)^2$
- p-value, ossia la forza nel rifiutare $H_0 : \beta_i = 0$.

Inizialmente il nostro modello lineare semplice viene caratterizzato dalla sola variabile di CPU che descrive la relazione con la variabile dipendente nel seguente modo:

$$Y = \beta_0 + \beta_1 Cpu + \varepsilon$$

dove β_0 *e* β_1 sono i coefficienti che definiscono, rispettivamente, l'intercetta e il contributo lineare al modello, mentre ε è la componente casuale della relazione che tiene conto della variabilità della variabile dipendente all'interno del modello dei dati.

In questo modo otteniamo:

```
Call:
lm(formula = PerformanceServer ~ CPU, data = data)

Residuals:
     Min       1Q   Median       3Q      Max
-18.7651  -4.5366   0.4314   6.3003  17.6449

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   81.584      1.057  77.172  < 2e-16 ***
CPU            3.613      1.068   3.384  0.00129 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.187 on 58 degrees of freedom
Multiple R-squared:  0.1649,    Adjusted R-squared:  0.1505
F-statistic: 11.45 on 1 and 58 DF,  p-value: 0.001285
```

dove:

- R^2 = 0.1649
- p-value = 0.001285
- RSS = 3887.6

Al modello generato, aggiungendo gli altri contributi forniti dalle altre variabili dipendenti e svolgendo così delle diverse prove emerge che alcuni parametri non forniscono contenuto informativo e di conseguenza può essere escluso. Tuttavia, in questo secondo tentativo, andando ad aggiungere la seconda variabile indipendente HardDisk il modello lineare viene caratterizzato nel seguente modo:

$$Y = \beta_0 + \beta_1 Cpu + \beta_2 HardDisk + \varepsilon$$

In questo modo viene aggiunto il nuovo parametro incognito β_2 che consiste in un secondo contributo lineare relativo la nuova variabile indipendente aggiunta.

In questo modo otteniamo:

```
Call:
lm(formula = PerformanceServer ~ CPU + HD, data = data)

Residuals:
     Min       1Q   Median       3Q      Max
-17.9256  -5.3145   0.8598   5.2294  19.6273

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  81.3773     0.9845  82.657  < 2e-16 ***
CPU           3.8712     0.9955   3.889 0.000266 ***
HD           -3.2294     1.0127  -3.189 0.002320 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7.608 on 57 degrees of freedom
Multiple R-squared:  0.2913,    Adjusted R-squared:  0.2665
F-statistic: 11.72 on 2 and 57 DF,  p-value: 5.464e-05
```

dove

- $R^2 = 0.2913$
- p-value = 5.464×10^{-5}
- RSS = 3299.0

Viene svolto un terzo step con l’aggiunta del terzo contributo significativo relativo alla variabile indipendente Congestione. Il modello lineare risultante viene caratterizzato nel seguente modo:

$$Y = \beta_0 + \beta_1 Cpu + \beta_2 HardDisk + \beta_3 Cong + \varepsilon$$

In questo modello, oltre ai parametri incogniti definiti precedentemente, viene aggiunto il parametro β_3 il quale rappresenta il contributo informativo e lineare relativo alla nuova variabile aggiunta.

In questo modo otteniamo:

```
Call:
lm(formula = PerformanceServer ~ CPU + HD + Congestione, data = data)

Residuals:
   Min     1Q Median     3Q    Max
-9.584 -3.490 -0.320  2.433 13.681

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  81.8454     0.6536 125.231  < 2e-16 ***
CPU           3.3685     0.6611   5.095 4.25e-06 ***
HD           -1.8795     0.6880  -2.732  0.00841 **
Congestione  -5.9585     0.6915  -8.617 7.56e-12 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 5.033 on 56 degrees of freedom
Multiple R-squared:  0.6953,    Adjusted R-squared:  0.679
F-statistic:  42.6 on 3 and 56 DF,  p-value: 1.796e-14
```

dove:

- $R^2 = 0.6953$
- p-value = 1.796×10^{-14}
- RSS = 1418.4

Infine, avendo notato durante l’analisi di correlazione una debole correlazione tra le variabili indipendenti Congestione e HD caratterizzate da un coefficiente R di 0.22, abbiamo deciso di introdurla all’interno del nostro modello statistico. Il modello risultante viene caratterizzato nel seguente modo:

$$Y = \beta_0 + \beta_1 Cpu + \beta_2 HardDisk + \beta_3 Cong + \beta_4 (Cong * HardDisk) + \varepsilon$$

In questo modello, oltre ai parametri incogniti definiti precedentemente, viene aggiunto il parametro β_4 il quale rappresenta il contributo informativo e lineare relativo alla nuova variabile aggiunta.

In questo modo otteniamo:

```
Call:
lm(formula = PerformanceServer ~ CPU + Congestione + HD + (Congestione *
    HD), data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-9.5370 -2.5719 -0.2403  2.4655 14.2105

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)     82.0054     0.6695 122.493  < 2e-16 ***
CPU              3.2264     0.6734   4.791  1.3e-05 ***
Congestione     -5.8882     0.6937  -8.489  1.4e-11 ***
HD              -1.7571     0.6965  -2.523   0.0146 *
Congestione:HD  -0.7535     0.7020  -1.073   0.2878
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 5.026 on 55 degrees of freedom
Multiple R-squared:  0.7016,    Adjusted R-squared:  0.6799
F-statistic: 32.32 on 4 and 55 DF,  p-value: 7.345e-14
```

dove:

- R^2= 0.7016
- p-value = 7.345 x 10^{-14}
- RSS = 1389.3

Nonostante questo modello risulta essere il migliore per i risultati ottenuti, viene svolta un'ulteriore conferma che si può trovare nel seguente test di ipotesi, performato tramite il comando **anova():**

```
Analysis of Variance Table

Model 1: PerformanceServer ~ Congestione + CPU + HD
Model 2: PerformanceServer ~ CPU + Congestione + HD + (Congestione * HD)
  Res.Df    RSS Df Sum of Sq      F Pr(>F)
1     56 1418.4
2     55 1389.3  1    29.097 1.1519 0.2878
```

Il significato dei vari indici viene indicato come segue:

- Res.Df, il numero di gradi di libertà residui, che rappresenta il numero di punti dati meno il numero di parametri stimati nel modello.
- RSS, la somma dei quadrati residui, che è una misura della differenza tra le risposte osservate e i valori stimati.
- Df, la differenza nei gradi di libertà tra i due modelli.
- Sum of Sq, la differenza nella somma dei quadrati residui tra i due modelli.
- F, l'F-statistica, che è il rapporto tra la variazione spiegata e la variazione residua.
- Pr(>F), il valore p, che misura la significatività dell'F-statistica.

Dai risultati di tale funzione **anova()**, è possibile osservare come, avente un valore p superiore a 0.05, non emerge una differenza significativa tra i due modelli. Per tale motivo preferiamo scegliere il seguente modello:

$$Y = \beta_0 + \beta_1 Cpu + \beta_2 HardDisk + \beta_3 Cong + \varepsilon$$

in modo tale da non fare troppo overtraining.

Il modello lineare risultante va ad escludere alcuni parametri del dataset: Buffer e Ram.

Questa decisione è stata presa sulla base del fatto che, nell'analisi di regressione eseguita precedentemente, il loro contributo informativo risulta molto trascurabile e quasi nullo. Tutto ciò viene anche rafforzato dal fatto che la loro correlazione con la variabile dipendente è praticamente approssimabile al valore nullo.

6. Stima dei minimi quadrati

È utile adesso introdurre alcuni concetti di statistica inferenziale. Questa disciplina statistica si occupa di sviluppare metodi che, a partire dall'analisi di un campione limitato di dati, permettono di dedurre informazioni sulle caratteristiche dell'intera popolazione, stimando specifici parametri. Stimare un parametro di una popolazione significa applicare una procedura che, attraverso il campionamento della popolazione considerata, fornisce informazioni quantitative sul valore del parametro sconosciuto. Esistono due tipi di stime:

- **Stima puntuale:** il valore incognito del parametro viene approssimato alla stima, ovvero il valore assunto dello stimatore in corrispondenza del campione osservato.
- **Stima intervallare:** prevede la definizione di un intervallo che contiene il possibile valore vero del parametro considerando un certo grado di incertezza α.

Elemento fondamentale della statistica inferenziale è il **metodo dei minimi quadrati**. Questo metodo è utilizzato per stimare i parametri di un modello di regressione lineare che minimizzano la somma dei quadrati degli errori di previsione.

$$SQE = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = min_{\hat{\beta}_0 \dots \hat{\beta}_n}\left\{ \sum_{i=1}^{n}\left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_n x_n)\right]^2 \right\}$$

Il metodo consente di determinare la forma funzionale degli stimatori $\hat{\beta}_0, \dots, \hat{\beta}_n$ imponendo che la somma dei quadrati delle differenze tra i valori osservati Y_i ed i valori stimati $\hat{Y}_i$ (fitted values) sia minima.

In R studio il comando lm() ci fornisce già una stima dei parametri del nostro modello, qui di seguito riportati:

```
Coefficients:
(Intercept)       x2_CPU        x3_HD      x4_Cong
     81.845        3.369       -1.879        -5.958
```

Da cui deriva che il modello ottenuto sia:

$$\hat{Y} = 81.85 - 3.37x1 - (-1.88x2) - (-5.96x3)$$

6.1. Stima degli intervalli di confidenza

Un intervallo di confidenza è un concetto fondamentale in statistica che rappresenta un intervallo di valori entro il quale si stima che un parametro della popolazione (come la media o la proporzione) si trovi con un certo livello di confidenza. L'idea di base è fornire una gamma di valori plausibili per il parametro della popolazione, piuttosto che un singolo punto di stima.

L'intervallo di confidenza da noi scelto è quello al 95%, quindi con un errore, ciò significa che confidiamo al 95% che l'intervallo generato conterrà il valore vero del parametro che stiamo considerando in termini di inferenza statistica.

Con il comando **Confint()** generiamo i nostri intervalli:

	2.5 %	97.5 %
(Intercept)	80.536181	83.1546377
Congestione	-7.343755	-4.5732291
CPU	2.044173	4.6929008
HD	-3.257715	-0.5012376

quindi:

Intercept: $\beta_0 \in [80.53 , 83.15]$

Congestione: $\beta_1 \in [-7.34 , -4.57]$

CPU: $\beta_2 \in [2.04 , 4.69]$

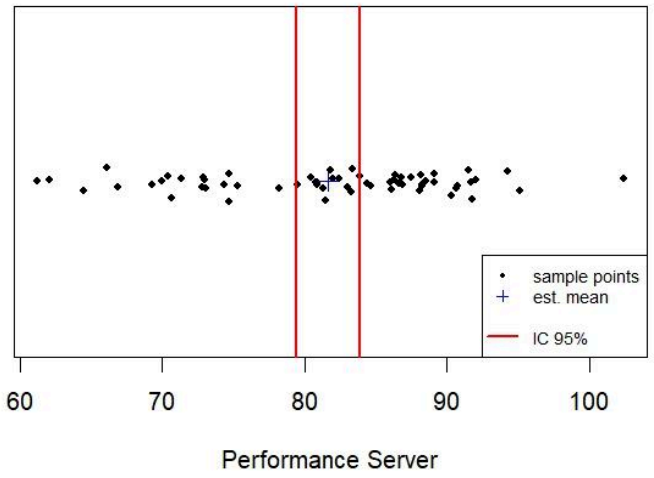
HD: $\beta_3 \in [-3.25 , -0.50]$

Gli intervalli di confidenza possono essere usati anche per comprendere se un regressore è rilevante o meno. Ciò si può fare attraverso un test di ipotesi sulla rilevanza di un regressore all'interno del modello considerando la stima del parametro in questione. Nel momento in cui il regressore è molto vicino allo zero avrà poca rilevanza, mentre se sarà molto lontano dal valore nullo sarà considerato più rilevante . Il test di ipotesi in questione è il seguente:

$$\begin{cases} H_0 : \beta_i = 0 \\ H_A : \beta_i \neq 0 \end{cases}$$

Se l'intervallo di confidenza contiene il valore zero allora si può considerare accettata l'ipotesi H_0 e si può concludere che il regressore non è rilevante. Da come è possibile osservare, non sono presenti intervalli che passano per lo zero e quindi i regressori trattati sono tutti rilevanti, come già considerato nel paragrafo dell'analisi delle relazioni tra variabili.

In termini di inferenza statistica, è possibile esaminare il seguente scatter plot per andare a definire il Lower e l'Upper Bound dell'intervallo di confidenza riguardante la stima del parametro incognito valore atteso della variabile dipendente "Performance":



I limiti in questione sono:

- Lower : L = 79.41266
- Upper : U = 83.90785

7. Analisi dei residui e diagnostica

Il coefficiente di determinazione R^2 è definito dal rapporto tra la variabilità SQR e la variabilità totale SQTOT:

$$R^2 = \frac{\sum_i (\hat{y}_i - \bar{y})^2}{\sum_i (y_i - \bar{y})^2} = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2} = \frac{SQTOT - SQE}{SQTOT} = \frac{SQR}{SQTOT}$$

in cui:

- **SQTOT** rappresenta la somma delle differenze tra ogni osservazione e la media delle osservazioni.
- **SQE** rappresenta quanto del totale della variabilità nei dati può essere spiegato dai predittori nel modello.
- **SQR** misura la dispersione dei residui, ovvero le differenze tra i valori osservati e quelli predetti dal modello.

Esso, pertanto, rappresenta una misura dell'importanza relativa che l'intero insieme di variabili indipendenti ha nell'interpretare il comportamento della variabile dipendente Y.

Il coefficiente di determinazione rappresenta la proporzione, o percentuale, di variazione nella variabile dipendente che è spiegata dal modello di regressione lineare . Nelle applicazioni reali, sarà compreso tra 0 ed 1: più è vicino a 1, meglio il modello lineare si adatta ai dati su cui sono stati stimati i parametri (training set).

Nel modello da noi creato, avremo:

- SQTOT = 4655,256
- SQE = 3236,837
- SQR = 1418,419
- R^2 = 0,6953

7.1. Verifica degli assunti di base del modello di regressione lineare

Quando si realizza un modello di regressione lineare, una delle prime cose da fare è l'analisi dei residui. La parte di variabilità che non è spiegata dal modello costituisce proprio il residuo della regressione e affinché tale modello di regressione riesca ad avere un buon potere predittivo, questo errore deve essere una variazione imprevedibile nella variabile risposta.

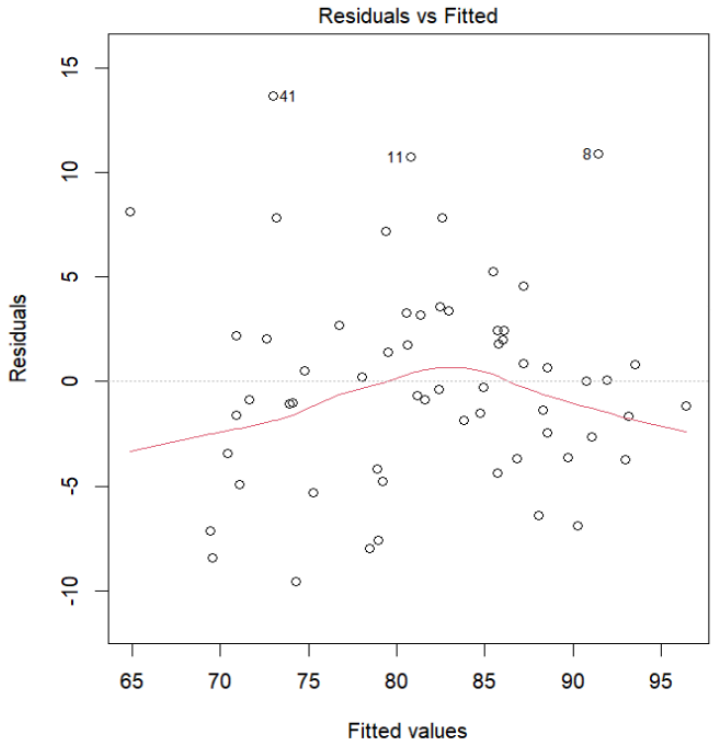
I valori residui in un'analisi di regressione rappresentato proprio la parte di errore di previsione del modello di regressione e, difatti, sono anche detti "scarti", rappresentando le differenze tra i valori osservati nel dataset e i valori stimati calcolati con l'equazione di regressione. In definitiva si può dire che indicano la variabilità dei dati attorno alla retta di regressione. Relativamente a quanto detto, le proprietà degli stimatori dei parametri del modello richiedono alcune assunzioni che bisogna quindi verificare. Queste sono:

- **Linearità**: gli errori devono essere a media nulla e simmetrici rispetto alla retta y=0;
- **Normalità**: gli errori si distribuiscono come una normale;

Linearità

Per verificare la linearità abbiamo confrontato attraverso uno scatter plot, i residui e i fitted values.

come possiamo osservare dal grafico, i punti sono distribuiti intorno ad una linea rossa che è una linea di tendenza, la quale risulta approssimativamente lineare e abbastanza sovrapponibile alla linea orizzontale tratteggiata (in corrispondenza dei residui con media zero), quindi possiamo concludere che l'ipotesi di linearità è verificata.



Per verificare che la media dei residui sia effettivamente nulla, lo facciamo tramite il test d'ipotesi T di Student, che ci dice se c'è o meno una differenza statisticamente significativa tra la media dei residui e lo 0. In particolare:

$$\begin{cases} H_0 : \mu = 0 \\ H_a : \mu \neq 0 \end{cases}$$

Dal test eseguito nell'ambiente R, otteniamo:

```
        One Sample t-test

data:  residui
t = 3.4637e-16, df = 59, p-value = 1
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -1.266621  1.266621
sample estimates:
   mean of x
2.192537e-16
```

Siccome il p-value è maggiore di 0.05 possiamo affermare che non vi è una differenza statisticamente significativa tra la media dei residui e lo 0

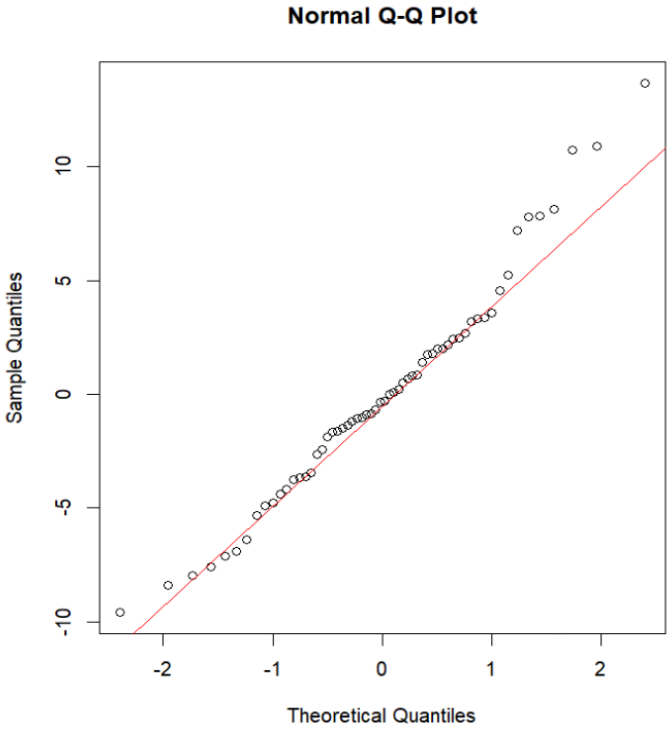
Normalità

Un modo semplice di verificare tale assunzione è di considerare i residui standardizzati, che devono distribuirsi, al crescere di n, secondo una Normale standardizzata.

La distribuzione normale degli errori può essere verificata attraverso un grafico dei quantili, detto anche q-q plot. In questa tipologia di grafico, i quantili teorici di una distribuzione Normale sono riportati sull'asse orizzontale, mentre i quantili dei residui standardizzati sono invece riportati sull'asse verticale.

L'idea è che se i residui hanno una distribuzione normale, i loro quantili dovrebbero coincidere con quelli della distribuzione Normale.

A livello visivo, questo significa che i punti dovrebbero disporsi lungo la bisettrice, indicata dalla retta presente nel grafico. Per poter dire che gli errori hanno una distribuzione normale ci si accontenta quindi che i punti siano vicino alla linea presente nel grafico.



8. Adattamento del modello di Regressione

Nell'analisi svolta fino a questo punto, la regressione è stata basata principalmente sul p-value, l'indice di determinazione R^2 e l'RSS. Tra i tanti elementi che influenzano la scelta di un modello rispetto ad un altro vi è la bontà di adattamento fra le osservazioni campionate e i valori previsti del modello stimato, la quale quando è bassa implica errori tra valori stimati e valori reali. Nonostante tale parametro risulta un punto di partenza per la valutazione di un modello, non bisogna considerarlo uno strumento universale in modo da non rischiare di portare a situazioni di overfitting. Per tale motivo è possibile utilizzare due criteri per il confronto tra due modelli che forniscono una misura della distanza tra il modello e la distribuzione teorica dei dati in relazione al numero di parametri stimati. I due criteri sono:

- **AIC** (o **Akaike Information Criterion**), il quale prevede la seguente formula:

$$AIC = -2log(L) + 2k$$

  dove L è il valore di massima verosimiglianza del modello e k il numero di parametri.

- **BIC (**o **Bayesian Information Criterion**), il quale prevede la seguente formula:

$$BIC = -2log(L) + log(n)k$$

dove L è il valore di massima verosimiglianza del modello, k il numero di parametri e n il numero di osservazioni.

Per poter selezionare l'ordine con il quale aggiungere i regressori portando così a diversi modelli di regressione a partire dello stesso insieme di variabili:

- Forward selection, metodo che parte dal modello di regressione semplice e aggiunge una variabile alla volta. Alla fine si seleziona il modello a seconda del valore del criterio.
- Backward selection, metodo che parte dal modello di regressione completo e si eliminano una alla volta tutte le variabili che risultano non significative. La procedura termina quando le variabili sono tutte significative.
- Stepwise selection o Hybrid, metodo che fa uso sia del forward che del backward selection. Il forward viene utilizzato per definire quale variabile deve essere inserita nel modello e backward per controllare quale variabile deve essere eliminata.

8.1. Forward Selection

Per quanto riguarda l'approccio forward selection, è stato utilizzato il seguente comando:

```
step(modelloiniziale,
     scope= list(lower= modelloiniziale, upper = modellototale),
     direction= "forward")
```

dove modelloiniziale rappresenta il modello di regressione semplice e modellototale indica un modello che prende in considerazione il contributo lineare, quadratico e cubico delle variabili indipendenti. Il risultato di tale comando è il seguente:

```
Start:  AIC=254.27
performance ~ cpu

       Df Sum of Sq    RSS    AIC
+ cong  1   2280.14 1607.4 203.28
+ hd    1    588.59 3299.0 246.42
<none>               3887.6 254.27
+ buff  1     77.18 3810.4 255.07
+ ram   1     24.70 3862.9 255.89

Step:  AIC=203.28
performance ~ cpu + cong

       Df Sum of Sq    RSS    AIC
+ hd    1   189.020 1418.4 197.78
+ buff  1   103.552 1503.9 201.29
<none>              1607.4 203.28
+ ram   1    16.652 1590.8 204.66

Step:  AIC=197.78
performance ~ cpu + cong + hd

       Df Sum of Sq    RSS    AIC
+ buff  1    53.311 1365.1 197.48
<none>              1418.4 197.78
+ ram   1    29.332 1389.1 198.52

Step:  AIC=197.48
performance ~ cpu + cong + hd + buff

       Df Sum of Sq    RSS    AIC
<none>              1365.1 197.48
+ ram   1    26.374 1338.7 198.31
```

Il modello risultante da tale analisi è il seguente:

```
Call:
lm(formula = performance ~ cpu + cong + hd + buff, data = dataset)

Coefficients:
(Intercept)          cpu         cong           hd         buff
     82.035        3.534       -6.040       -1.652        1.039
```

Da come è possibile notare, viene aggiunto il contributo del buffer diversamente da ciò che avevamo valutato con il modello stimato.

8.2. Backward Selection

Per quanto riguarda la metodologia della backward selection viene utilizzato il seguente comando:

```
step(modellototale, direction= "backward")
```

Il risultato di tale espressione è il seguente:

```
Start:  AIC=198.31
performance ~ ram + ram^2 + ram^3 + cpu + cpu^2 + cpu^3 + hd +
    hd^2 + hd^3 + cong + cong^2 + cong^3 + buff + buff^2 + buff^3

       Df Sum of Sq    RSS    AIC
- ram   1     26.37 1365.1 197.48
<none>              1338.7 198.31
- buff  1     50.35 1389.1 198.52
- hd    1    149.84 1488.6 202.67
- cpu   1    698.08 2036.8 221.49
- cong  1   1896.75 3235.5 249.25

Step:  AIC=197.48
performance ~ cpu + hd + cong + buff

       Df Sum of Sq    RSS    AIC
<none>              1365.1 197.48
- buff  1     53.31 1418.4 197.78
- hd    1    138.78 1503.9 201.29
- cpu   1    702.90 2068.0 220.40
- cong  1   1919.61 3284.7 248.16

Call:
lm(formula = performance ~ cpu + hd + cong + buff)

Coefficients:
(Intercept)          cpu           hd         cong         buff
     82.035        3.534       -1.652       -6.040        1.039
```

Anche in questo caso è possibile notare che il modello risultante risulta differente da quello stimato a causa dell'aggiunta del contributo riguardante la variabile indipendente "buffer". Inoltre in questa analisi, è possibile evidenziare come i contributi quadratici e cubici vengano eliminati in quanto non significativi.

8.3. Stepwise Selection

Infine per quanto riguarda la metodologia dello stepwise selection viene utilizzato il seguente comando:

```
step(modelloiniziale,
     scope = list(lower= modelloiniziale, upper=modellototale),
     direction= "both")
```

Il risultato di tale comando è il seguente:

```
Start:  AIC=254.27
performance ~ cpu

       Df Sum of Sq    RSS    AIC
+ cong  1   2280.14 1607.4 203.28
+ hd    1    588.59 3299.0 246.42
<none>              3887.6 254.27
+ buff  1     77.18 3810.4 255.07
+ ram   1     24.70 3862.9 255.89

Step:  AIC=203.28
performance ~ cpu + cong

       Df Sum of Sq    RSS    AIC
+ hd    1    189.02 1418.4 197.78
+ buff  1    103.55 1503.9 201.29
<none>              1607.4 203.28
+ ram   1     16.65 1590.8 204.66
- cong  1   2280.14 3887.6 254.27

Step:  AIC=197.78
performance ~ cpu + cong + hd

       Df Sum of Sq    RSS    AIC
+ buff  1     53.31 1365.1 197.48
<none>              1418.4 197.78
+ ram   1     29.33 1389.1 198.52
- hd    1    189.02 1607.4 203.28
- cong  1   1880.58 3299.0 246.42

Step:  AIC=197.48
performance ~ cpu + cong + hd + buff

       Df Sum of Sq    RSS    AIC
<none>              1365.1 197.48
- buff  1     53.31 1418.4 197.78
+ ram   1     26.37 1338.7 198.31
- hd    1    138.78 1503.9 201.29
- cong  1   1919.61 3284.7 248.16
```

Il modello risultante da tale metodologia è il seguente:

```
Call:
lm(formula = performance ~ cpu + cong + hd + buff, data = dataset)

Coefficients:
(Intercept)          cpu         cong           hd         buff
     82.035        3.534       -6.040       -1.652        1.039
```

Anche in questo caso viene reso significativo il contributo della variabile indipendente “buffer”.

Considerando che tutte e tre le metodologie forniscono lo stesso risultato andiamo a controllare se il seguente modello risultante:

$$Y = \beta_0 + \beta_1 Cpu + \beta_2 Cong + \beta_3 Hd + \beta_4 Buff + \varepsilon$$

risulta migliore di quello stimato da noi. Per fare ciò andiamo ad utilizzare gli indici di bontà di adattamento, come precedentemente indicato. I comandi utilizzati sono i seguenti:

```
extractAIC(modellofinale, scale = 0, k = 3)
extractAIC(modellostep, scale = 0, k = 4)
extractAIC(modellofinale, scale = 0, k = log(60))
extractAIC(modellostep, scale = 0, k = log(60))
```

Da cui vengono ottenuti i seguenti valori:

AICModelloFinale = 201.7772

AICModelloStep = 207.4787

BICModelloFinale = 206.1546

BICModelloStep = 207.9504

Da tali indici si è arrivati alla conclusione che il modello finale stimato da noi risulta migliore rispetto a quello generato dalla regressione stepwise.

9. Presentazione ed analisi dei risultati

Tale progetto ha lo scopo di andare a fornire il modello di regressione basandosi sulle osservazioni svolte. Tale modello serve a descrivere al meglio la dipendenza della variabile dipendente “Performance Server” con le diverse variabili indipendenti: “Ram”, “Cpu”, “Hd”, “Congestione”, “Buffer”. Descriviamo i vari step che hanno portato al modello finale:

1. Analisi dei dati con l’aiuto della statistica descrittiva, fase nella quale sono state fornite un'analisi preliminare e alcune informazioni più dettagliate sulle variabili da usare per la determinazione del modello. In tale fase sono stati esaminati gli indici di posizione e di distorsione, la distribuzione di frequenza relativa e cumulata e la correlazione tra le variabili. Tale analisi ci permette di definire se vi è una forte o una debole correlazione tra le variabili e decidere se escludere o meno dalla determinazione del modello.
2. Analisi delle relazioni tra variabili, fase nella quale è stata esaminata la relazione tra la variabile dipendente e le singoli variabili indipendenti attraverso l’uso di strumenti come il p-value, il coefficiente di determinazione e l’RSS. Tale indagine ha permesso di identificare quali fossero le variabili che fornivano un contributo informativo più significativo.
3. Determinazione del modello statistico. In questa fase è stato determinato un possibile modello statistico da utilizzare per la descrizione della dipendenza sopra citata. Attraverso l’ausilio di R è stato possibile analizzare i risultati direzionando il modello verso un modello lineare semplice. Il modello preso in esame è il seguente:

$$Y = \beta_0 + \beta_1 Cpu + \beta_2 HardDisk + \beta_3 Cong + \varepsilon$$

dove:

- $R^2 = 0.6953$
- p-value = 1.796×10^{-14}
- RSS = 1418.4

Da notare che sono state escluse le variabili riguardanti il “Buffer” e la “Ram” in quanto fornivano un contenuto informativo trascurabile e non significativo.

4. Stime ai minimi quadrati. In questa fase sono state determinate delle stime dei parametri incogniti del modello risultante attraverso il metodo dei minimi quadrati. Inizialmente è stata definita una stima puntuale per poi passare anche ad una stima intervallare in modo da avere maggiore contenuto informativo.
5. Analisi dei residui. In questa fase è stato calcolato il coefficiente di determinazione e viene fatta un'indagine sulle differenze tra i valori osservati e quelli stimati dall’equazione di regressione. In definitiva si può dire che indicano la variabilità intorno alla retta di regressione
6. Regressione stepwise. In questa fase si determina il modello di regressione stepwise e si esamina quale modello risulta migliore confrontandolo con quello determinato precedentemente. Per svolgere tale analisi vengono utilizzati i criteri AIC e BIC. In questa parte del progetto è stato determinato un secondo modello:

$$Y = \beta_0 + \beta_1 Cpu + \beta_2 Cong + \beta_3 Hd + \beta_4 Buff + \varepsilon$$

Tale modello, però, risulta peggiore di quello determinato da noi. Per tale motivo è stato preferito scegliere quello iniziale. In particolare gli indici calcolati sono stati i seguenti:

- AICModelloFinale = 201.7772
- AICModelloStep = 207.4787
- BICModelloFinale = 206.1546
- BICModelloStep = 207.9504